

C L A S E 1

Visualización de Datos

De los datos a la visualización univariada

Diplomado en Visualización de Datos

Universidad del Valle · Profesor: Manuel Luna

Módulos

	Módulo 1	Fundamentos de Visualización de Datos: Principios, Tipos y Narrativa Visual
	Módulo 2	Visualización con Tableau
	Módulo 3	Introducción a Power BI
	Módulo 4	Creación de Reportes con Looker Studio
	Módulo 5	Creación de Visualizaciones en R
	Módulo 6	Creación de Dashboards Interactivos

Lo que vamos a hacer en estas 3 horas

- 1 ¿Por qué visualizamos? Anscombe + Datasaurus
- 2 ¿Para qué visualizamos? · Integridad gráfica
- 3 Cómo lee el cerebro un gráfico
- 4 Tipos de datos y mnemotécnica
- 5 Break
- 6 Univariada cualitativa
- 7 Univariada cuantitativa
- 8 Color y data-ink ratio
- 9 Cierre

Perfil Profesional

Manuel E. Luna Alegría

Estadístico · Data Scientist · AI Engineer



Educación

M.Sc. Data Science & Artificial Intelligence – UAO (Current)

Estadístico – Universidad del Valle

Experiencia Laboral



Data Scientist - Actual



Adjunct Professor



Data & BI Engineer



Fraud Prevention Lead



Senior Data Analyst



[linkedin.com/in/meluna](https://www.linkedin.com/in/meluna)



3127051597

EL PROCESO DE STORYTELLING CON ESCENARIOS: DE LA NARRATIVA A LA DECISIÓN ESTRATÉGICA


1 INICIO DE LA HISTORIA Y CONTEXTO



1 Define el Contexto, el Problema y las Variables Fundamentales.

2 DESARROLLO DE ESCENARIOS (LA MATRIZ DE INCERTIDUMBRES)

Crea historias plausibles de múltiples futuros.



Crea historias plausibles de múltiples futuros.


3 ANÁLISIS DE IMPACTOS Y HOJA DE RUTA

Evalúa consecuencias y define implicaciones estratégicas.



4 GRÁFICO DE TOMA DE DECISIONES

ÁRBOL DE DECISIONES Y PRIORIZACIÓN



ÁRBOL DE DECISIONES Y PRIORIZACIÓN

Toma decisiones informadas basadas en el análisis de escenarios.


"The simple graph has brought more information to the data analyst's mind than any other device."

— John Tukey (1977)



Cuatro datasets, una sola estadística

Cuarteto de Anscombe — mismas estadísticas, formas radicalmente distintas




$\bar{x}=9.0$ $\bar{y}=7.5$ $r=0.82$ $y=3+0.5x$ en los cuatro sets

- Mismas medias, varianzas y r de Pearson.
- Formas radicalmente distintas.
- Conclusión: jamás reportes correlación sin graficar primero.

Datasaurus Dozen — mismas estadísticas, distintas formas

Datasaurus Dozen — todos comparten media, sd y $r \approx$ idénticos



Matejka & Fitzmaurice (2017) demostraron que se pueden generar datasets con estadísticas idénticas y formas completamente distintas. La visualización es el único lente que descubre estas diferencias.

¿Para qué visualizamos?

1

Resumir

Comprimir miles de filas en una imagen leíble.

2

Explorar

Detectar patrones que el resumen estadístico no muestra (EDA).



3

Comunicar

Habilitar una decisión: que la audiencia vea, entienda y actúe.

Mismos datos, dos lecturas

Mismos datos, dos lecturas — la integridad gráfica de Tufte




El "lie factor" mide la diferencia entre el efecto visual y el cambio real en los datos. Truncar el eje Y multiplica visualmente lo que estadísticamente apenas se mueve. Regla: para variables con cero significativo, ejes desde cero.

PARTE 1 · PERCEPCIÓN VISUAL

Cómo lee el cerebro un gráfico

El cerebro encuentra el outlier en menos de 250 ms

Atributo preatentivo: el cerebro detecta el outlier en menos de 250 ms



Los atributos preatentivos (color, tamaño, orientación, posición espacial) son procesados antes de que dirijamos la atención conscientemente. Son la materia prima de un gráfico efectivo.

Tamaño y orientación también disparan pop-out

Otros canales preatentivos: tamaño y orientación



Combinar dos canales preatentivos (color + tamaño, por ejemplo) refuerza el pop-out. Pero más de tres se cancelan entre sí — el ojo deja de saber dónde mirar.

Cómo agrupamos lo que vemos

Proximidad

Elementos cercanos se perciben como grupo.

Similitud

Misma forma o color = misma categoría.

Continuidad

El ojo sigue líneas y curvas suaves.

Cierre


Completamos formas incompletas mentalmente.

Figura-fondo

Distinguimos un objeto de su contexto.

Cleveland & McGill: la jerarquía que manda

Jerarquía perceptual — Cleveland & McGill (1984)




- El cerebro decodifica posición común con altísima precisión.
- Decodifica color y volumen con muy baja precisión.
- Por eso una BARRA gana siempre a un PIE 3D.
- Y un PIE plano ya es marginal frente a una barra.


Mismos datos. Lectura completamente distinta.

Mismos datos. La barra usa POSICIÓN (alta precisión); el pie usa ÁNGULO (baja).

Barra: lectura inmediata



Pie: ¿cuál es mayor?



En la barra: Office Supplies > Furniture es inmediato. En el pie: hay que comparar ángulos casi idénticos.

PARTE 2 · TIPOS DE DATOS

*Cada variable pide su
gráfico*

Cualitativas y cuantitativas — y qué gráfico les corresponde

Tipos de datos y la familia visual que les corresponde

Tipo	Definición	Ejemplo (Superstore)	Familia visual
Cualitativo nominal	categorías sin orden	Region · Segment · Category	Barras / lollipop
Cualitativo ordinal	categorías con orden	Order Priority · Calificación	Barras ordenadas / dot plot
Cuantitativo discreto	conteos enumerables	Quantity · # de pedidos	Histograma · barras
Cuantitativo continuo	valores reales	Sales · Profit · Discount	Histograma · densidad · boxplot
Temporal	tiempo (orden + métrica)	Order Date	Line · slopegraph · calendar
Geoespacial	ubicación	State · Latitude/Longitude	Choropleth · símbolos

¿Puedo resumir esta variable con la media?

SÍ

Cuantitativa

Sales, Profit, Quantity, Discount

NO

Cualitativa


Region, Segment, Category, Priority

Truco práctico para distinguir en 3 segundos qué tipo de variable tienes.

PARTE 3 · UNIVARIADA CUALITATIVA


Frecuencias y proporciones

Barras: posición común = máxima precisión




- Ordena de mayor a menor para facilitar lectura.
- Etiquetas dentro o al final de la barra.
- Resalta una sola categoría con color (atributo preatentivo).
- Quita gridlines y bordes innecesarios.

Lollipop: misma información, mejor data-ink ratio




- El extremo del lollipop comunica el valor.
- El tallo se elimina visualmente: menos tinta, igual mensaje.
- Útil cuando hay muchas categorías (>10).

Comparar varias series sin saturar de barras




El pie chart: por qué (casi) nunca

Pie con explosión — ¿cuál es la 2.ª más vendida?



Mismas categorías ordenadas por valor



El pie codifica con ÁNGULO (canal de baja precisión). Cuando son ≥ 4 categorías o las proporciones son cercanas, la barra siempre gana. La explosión y el 3D solo agravan el problema.

PARTE 4 · UNIVARIADA CUANTITATIVA

Distribuciones, formas y outliers

La forma de la distribución a primera vista


Distribución del Profit por orden — sesgada y con cola izquierda



- Eje X: rangos de la variable (bins).
- Eje Y: frecuencia (o densidad).
- Lectura: forma · centralidad · dispersión · cola.
- Anotar el cero o la mediana ayuda a leer.


El binning cambia la historia

Mismos datos, tres binnings — la decisión cambia la historia




Pocos bins esconden la forma; muchos la fragmentan. Reglas útiles: Sturges (n pequeñas), Freedman-Diaconis (robusto a outliers). Siempre justifica la elección.

Boxplot — mediana, IQR y outliers




- Mediana (línea central).
- Caja = IQR (Q1–Q3).
- Bigotes $\leq 1.5 \times \text{IQR}$ (Tukey).
- Puntos = outliers candidatos.
- Ordena por mediana, no alfabéticamente.

Violín: forma + resumen en un solo display



- Combina densidad y boxplot.
- Detecta bimodalidad (que el boxplot oculta).
- Funciona bien con n medio-grande (>200).
- Cuidado con la cola: cut=0 evita extrapolar.

Ridgeline: varias distribuciones de un vistazo



- Apila densidades con leve overlap.
- Mantiene el eje X compartido — comparación directa.
- Funciona hasta ~8 grupos, luego satura.
- Inspirado en la portada de Joy Division (Unknown Pleasures).

¿Cuándo usar cada uno?

Histograma

Forma exacta, n medio. Sensible al binning.

Densidad

Forma suave, comparar 2–3 grupos.

Boxplot

Resumen robusto + outliers. $n > 20$.

Violín

Forma + resumen. $n > 200$.

Ridgeline

Muchos grupos comparados (≤ 8).

PARTE 5 · COLOR Y DATA-INK


El color tiene gramática

Tres familias — y la regla para elegir

Secuencial — datos ordenados (e.g., densidad de población)



Divergente — datos con punto neutro (e.g., profit $\pm$ 0)




Cualitativa — categorías sin orden (e.g., Region)




- Secuencial — datos ordenados sin polo (densidad, ingresos).
- Divergente — datos con punto neutro (profit $\pm$ 0, anomalía).
- Cualitativa — categorías sin orden (Region, Segment).

El 8 % de los hombres no distingue rojo y verde

Rojo/verde — invisible para CVD ($\approx 8\%$ hombres)



Okabe-Ito — accesible para CVD





- Usa Okabe-Ito (8 colores accesibles) o ColorBrewer.
- Verifica con simuladores (Color Oracle, Coblis).
- Acompaña color con forma o etiqueta — redundancia perceptual.

Data-ink ratio: maximiza la tinta que es DATO

$$\textit{Data-ink ratio} = \frac{\text{tinta de datos}}{\text{tinta total}}$$

Tufte (1983): el cociente entre la tinta usada para representar datos y la tinta total del gráfico. Cualquier elemento que no represente datos — gridlines pesadas, fondos decorativos, sombras, 3D, rellenos — debería defenderse o eliminarse.

El mismo dato. Sin distracciones.



Hatching, gridlines pesadas, paleta arcoíris, bordes negros, sombras: todo eso es ruido. Limpiar = subir el data-ink ratio.

CIERRE · LO QUE TE LLEVAS

Tres ideas que no se olvidan

Tres ideas no negociables

01

El gráfico depende del tipo de variable

Cualitativa → frecuencia/proporción. Cuantitativa → forma/dispersión.

02

La barra le gana al pie casi siempre

Posición común > ángulo en la jerarquía de Cleveland & McGill.

03

Más data-ink, menos chartjunk

Cada elemento del gráfico debe ganarse el espacio que ocupa.

Reescribe un gráfico publicado

- Elige un gráfico de prensa, redes o un reporte público.
- Identifica al menos 2 problemas (chartjunk, escala, paleta, jerarquía).

Recursos recomendados

Libros

Tufte (2001) · Few (2012) · Wilke (2019, online) · Cairo (2016)

Papers

Cleveland & McGill (1984) · Anscombe (1973) · Datasaurus (Matejka & Fitzmaurice 2017)

Web

clauswilke.com/dataviz · colorbrewer2.org · jfly.uni-koeln.de/color

Datasets

Sample Superstore (Tableau) · Anscombe · Datasaurus · Penguins

Gracias